

大家好，这篇是有关台大机器学习课程作业五的详解。

我的github地址：

<https://github.com/Doraemonzzz>

个人主页：

<http://doraemonzzz.com/>

作业地址：

<https://www.csie.ntu.edu.tw/~htlin/course/ml15fall/>

参考资料：

<https://blog.csdn.net/a1015553840/article/details/51085129>

<http://www.vynguyen.net/category/study/machine-learning/page/6/>

<http://book.caltech.edu/bookforum/index.php>

<http://beader.me/mlnotebook/>

<https://blog.csdn.net/qian1122221/article/details/50130093>

## Problem 1

回顾下问题的形式

$$\begin{aligned} \min_{w,b,\xi} : & \frac{1}{2} w^T w + C \sum_{n=1}^N \xi_n \\ \text{subject to: } & y_n(w^T x_n + b) \geq 1 - \xi_n \\ & \xi_n \geq 0 (n = 1, \dots, N) \end{aligned}$$

$x_n, y_n$  为变量， $C$  为人为设定的超参数，其余量均为参数，注意  $w \in \mathbb{R}^d$ ，所以我们的参数有

$$w = (w_1, \dots, w_d), \xi_1, \dots, \xi_N, d$$

一共  $d + N + 1$  个。限制条件为

$$\begin{aligned} y_n(w^T x_n + b) & \geq 1 - \xi_n \\ \xi_n & \geq 0 (n = 1, \dots, N) \end{aligned}$$

一共有  $2N$  个。

## Problem 2

首先作图看下

```
# -*- coding: utf-8 -*-
"""
Created on Sat Mar 23 13:11:34 2019

@author: qinzhen
```

```
.....
```


```
import numpy as np
import matplotlib.pyplot as plt
from sklearn import svm

####Problem 2

#原始图
x = np.array([[1, 0],[0, 1],[0, -1],[-1, 0],[0, 2],[0, -2],[-2, 0]])
z = np.array([-1, -1, -1, +1, +1, +1, +1])

x1 = x[z>0][:, 0]
y1 = x[z>0][:, 1]
x2 = x[z<0][:, 0]
y2 = x[z<0][:, 1]

plt.scatter(x1,y1)
plt.scatter(x2,y2)
plt.show()
```



可以看到，如果用二次曲线的话，应该可以分类，现在做特征转换之后的图像。

转换之后的标记为+1的点为

$$z_4 = (5, -2), z_5 = (7, -7), z_6 = (7, 1), z_7 = (7, 1)$$

转换之后的标记为-1的点为

$$z_1 = (1, -2), z_2 = (4, -5), z_3 = (4, -1)$$

```
#特征转换之后的图
def phi_1(x):
    return x[1] ** 2 - 2 * x[0] + 3

def phi_2(x):
    return x[0] ** 2 - 2 * x[1] - 3

x = []
```


```

for i in x:
    x.append([phi_1(i), phi_2(i)])
X = np.array(X)

x1 = X[z>0][:, 0]
y1 = X[z>0][:, 1]
x2 = X[z<0][:, 0]
y2 = X[z<0][:, 1]

plt.scatter(x1,y1)
plt.scatter(x2,y2)
plt.show()

```



从这个图像中可以看出，最大间隔分类器为 $\phi_1(x) = 4.5$ ，将 $\phi_1(x) = x_2^2 - 2x_1 + 3$ 带入可得最大间隔分类器为

$$x_2^2 - 2x_1 + 3 = 4.5$$

$$x_1 = \frac{x_2^2 - 1.5}{2}$$


最后看下曲线的图。

```

#曲线图
y3 = np.arange(-2, 2, 0.01)
x3 = np.array([(i * i - 1.5) / 2 for i in y3])

plt.scatter(x1, y1)
plt.scatter(x2, y2)
plt.scatter(x3, y3, s=1)
plt.show()

```



### Problem 3

利用sklearn处理即可，这里设置参数shrinking=False，参数含义如下：

<https://stats.stackexchange.com/questions/24414/svm-options-in-scikit-learn>

```
clf = svm.SVC(kernel='poly', degree=2, coef0=1, gamma=1, C=1e10, shrinking=False)
clf.fit(x, z)
```

```
SVC(C=10000000000.0, cache_size=200, class_weight=None, coef0=1,
    decision_function_shape='ovr', degree=2, gamma=1, kernel='poly',
    max_iter=-1, probability=False, random_state=None, shrinking=False,
    tol=0.001, verbose=False)
```

看下哪几个向量为支持向量。

```
clf.support_
```

```
array([1, 2, 3, 4, 5])
```

这说明第2到6个向量均为支持向量，再来看下对偶问题的系数。

```
clf.dual_coef_
```

```
array([[ -0.64491963,  -0.76220325,  0.88870349,  0.22988879,  0.2885306 ]])
```

这些系数分别支持向量对应的系数，非支持向量对应的系数为0，这里还要注意一点，对偶问题的系数为 $y_n \alpha_n$ ，所以如果我们要得到原系数，就要乘以 $y_n$

```
z[clf.support_] * clf.dual_coef_[0]
```

```
array([0.64491963, 0.76220325, 0.88870349, 0.22988879, 0.2885306 ])
```

所以

$$(\alpha_1, \alpha_2, \alpha_3, \alpha_4, \alpha_5, \alpha_6, \alpha_7) = (0, 0.64491963, 0.76220325, 0.88870349, 0.22988879, 0.2885306, 0)$$

支持向量为

$$x_2, x_3, x_4, x_5, x_6$$

## Problem 4

为了求得曲线方程，我们需要利用以下几个式子

$$\begin{aligned} w &= \sum_{\alpha_n^* > 0} y_n \alpha_n^* z_n^T \\ b &= y_s - w^T z_s \\ g(x) &= \text{sign} \left( \sum_{\alpha_n^* > 0} y_n \alpha_n^* K(x_n, x) + b \right) \end{aligned}$$

注意

$$K(x_n, x) = (1 + x_n^T x)^2$$

首先计算 $b$ ，可以直接获得：

```
b = clf.intercept_[0]
b
```

```
-1.6663314053609206
```

接着计算 $K(x_n, x) = (1 + x_n^T x)^2$ ，首先找出支持向量：

```
x[clf.support_]
```

```
array([[ 0,  1],
       [ 0, -1],
       [-1,  0],
       [ 0,  2],
       [ 0, -2]])
```

然后计算上式，记

$$x = (x^{(1)}, x^{(2)})$$

那么每一项分别为：

$$\begin{aligned} &(1 + x^{(2)})^2 \\ &(1 - x^{(2)})^2 \\ &(1 - x^{(1)})^2 \\ &(1 + 2x^{(2)})^2 \\ &(1 - 2x^{(2)})^2 \end{aligned}$$

最后计算 $\alpha_n y_n$ ，直接调用即可：

```
clf.dual_coef_[0]
```

```
array([-0.64491963, -0.76220325,  0.88870349,  0.22988879,  0.2885306  ])
```

所以曲线方程为：

$$-0.64491963(1 + x^{(2)})^2 - 0.76220325(1 - x^{(2)})^2 + 0.88870349(1 - x^{(1)})^2 + 0.22988879(1 + 2x^{(2)})^2 + 0.2885306(1 - 2x^{(2)})^2 - 1.6663314053609206 = 0$$

## Problem 5

这里作图来看：


```
#点的数量
n = 1000
r = 3

#作点
a = np.linspace(-r, r, n)
b = np.linspace(-r, r, n)

#构造网格
A, B = np.meshgrid(a, b)
X = np.c_[A.reshape(-1, 1), B.reshape(-1, 1)]
label = np.reshape(clf.predict(X), A.shape)

#绘制等高线
plt.contour(A, B, label, 0)

plt.scatter(x1, y1)
plt.scatter(x2, y2)
plt.show()
```



可以看到，图像和之前的抛物线是不一样的。

## Problem 6

结合课件的推导，我们可知

$$L(R, c, \lambda) = R^2 + \sum_{n=1}^N \lambda_n (\|x_n - c\|^2 - R^2)$$

$$\lambda_n \geq 0$$

所以在  $\|x_n - c\|^2 \leq R^2$  条件下

$$\sum_{n=1}^N \lambda_n (\|x_n - c\|^2 - R^2) \leq 0$$

$$\max \left\{ \sum_{n=1}^N \lambda_n (\|x_n - c\|^2 - R^2) \right\} = 0$$

从而

$$\min_{R \in \mathbb{R}, c \in \mathbb{R}^d} \max_{\lambda_n \geq 0} L(R, c, \lambda) = \min_{R \in \mathbb{R}, c \in \mathbb{R}^d} R^2$$

## Problem 7

将上述问题转化为对偶问题

$$\min_{R \in \mathbb{R}, c \in \mathbb{R}^d} \max_{\lambda_n \geq 0} L(R, c, \lambda) = \max_{\lambda_n \geq 0} \min_{R \in \mathbb{R}, c \in \mathbb{R}^d} L(R, c, \lambda)$$

所以现在可以对  $L(R, c, \lambda)$  求无条件极值，分别求偏导可得

$$\begin{aligned}
\frac{\partial L(R, c, \lambda)}{\partial c} &= \frac{\partial [R^2 + \sum_{n=1}^N \lambda_n (||x_n - c||^2 - R^2)]}{\partial c} \\
&= \frac{\partial [R^2 + \sum_{n=1}^N \lambda_n (x_n^T x_n - 2x_n^T c + c^T c - R^2)]}{\partial c} \\
&= \frac{\partial [R^2 + \sum_{n=1}^N \lambda_n (x_n^T x_n - 2x_n^T c + c^T c - R^2)]}{\partial c} \\
&= \sum_{n=1}^N \lambda_n \frac{\partial (x_n^T x_n - 2x_n^T c + c^T c - R^2)}{\partial c} \\
&= \sum_{n=1}^N \lambda_n (2c - 2x_n) \\
&= 2(c \sum_{n=1}^N \lambda_n - \sum_{n=1}^N \lambda_n x_n)
\end{aligned}$$

令  $\frac{\partial L(R, c, \lambda)}{\partial c} = 0$  可得

$$c \sum_{n=1}^N \lambda_n - \sum_{n=1}^N \lambda_n x_n = 0$$

如果

$$\sum_{n=1}^N \lambda_n \neq 0$$

那么

$$c = \frac{\sum_{n=1}^N \lambda_n x_n}{\sum_{n=1}^N \lambda_n}$$

接着关于  $R$  求偏导

$$\begin{aligned}
\frac{\partial L(R, c, \lambda)}{\partial R} &= \frac{\partial [R^2 + \sum_{n=1}^N \lambda_n (||x_n - c||^2 - R^2)]}{\partial R} \\
&= 2R - 2 \sum_{n=1}^N \lambda_n R
\end{aligned}$$

令  $\frac{\partial L(R, c, \lambda)}{\partial R} = 0$  可得

$$\sum_{n=1}^N \lambda_n = 1$$

结合这个条件，关于  $c$  的条件可以简化



$$c = \frac{\sum_{n=1}^N \lambda_n x_n}{\sum_{n=1}^N \lambda_n} = \sum_{n=1}^N \lambda_n x_n$$

## Problem 8

将 $\sum_{n=1}^N \lambda_n = 1, c = \sum_{n=1}^N \lambda_n x_n$ 这两个条件带入 $L(R, c, \lambda)$ , 先带入 $\sum_{n=1}^N \lambda_n = 1$

$$\begin{aligned} L(R, c, \lambda) &= R^2 + \sum_{n=1}^N \lambda_n (\|x_n - c\|^2 - R^2) \\ &= \sum_{n=1}^N \lambda_n \|x_n - c\|^2 + R^2 - R^2 \sum_{n=1}^N \lambda_n \\ &= \sum_{n=1}^N \lambda_n \|x_n - c\|^2 \end{aligned}$$

再对 $\sum_{n=1}^N \lambda_n \|x_n - c\|^2$ 进行处理可得

$$\begin{aligned} L(R, c, \lambda) &= \sum_{n=1}^N \lambda_n \|x_n - c\|^2 \\ &= \sum_{n=1}^N \lambda_n (x_n^T x_n - 2x_n^T c + c^T c) \\ &= \sum_{n=1}^N \lambda_n x_n^T x_n - 2(\sum_{n=1}^N \lambda_n x_n^T) c + c^T c \sum_{n=1}^N \lambda_n \\ &= \sum_{n=1}^N \lambda_n x_n^T x_n - 2(\sum_{n=1}^N \lambda_n x_n^T) c + c^T c \end{aligned}$$

再带入 $c = \sum_{n=1}^N \lambda_n x_n$

$$\begin{aligned} L(R, c, \lambda) &= \sum_{n=1}^N \lambda_n x_n^T x_n - 2c \sum_{n=1}^N \lambda_n x_n^T + c^T c \\ &= \sum_{n=1}^N \lambda_n x_n^T x_n - 2(\sum_{n=1}^N \lambda_n x_n^T)(\sum_{n=1}^N \lambda_n x_n) + (\sum_{n=1}^N \lambda_n x_n^T)(\sum_{n=1}^N \lambda_n x_n) \\ &= \sum_{n=1}^N \lambda_n x_n^T x_n - (\sum_{n=1}^N \lambda_n x_n^T)(\sum_{n=1}^N \lambda_n x_n) \end{aligned}$$

所以问题转换为

$$\text{在条件 } \sum_{n=1}^N \lambda_n = 1, \lambda_n \geq 0 \text{ 下,}$$

$$\text{最小化 } f(\lambda) = \sum_{n=1}^N \lambda_n x_n^T x_n - \left( \sum_{n=1}^N \lambda_n x_n^T \right) \left( \sum_{n=1}^N \lambda_n x_n \right)$$

## Problem 9

这题是要利用  $z_n = \phi(x_n)$  以及  $K(x_n, x_m)$  来简化问题，先对  $f(\lambda)$  进行处理

$$\begin{aligned} f(\lambda) &= \sum_{n=1}^N \lambda_n x_n^T x_n - \left( \sum_{n=1}^N \lambda_n x_n^T \right) \left( \sum_{n=1}^N \lambda_n x_n \right) \\ &= \sum_{n=1}^N \lambda_n x_n^T x_n - \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m x_n^T x_m \end{aligned}$$

将  $x_n$  替换为  $z_n = \phi(x_n)$ ，然后代入  $K(x_n, x_m) = z_n^T z_m$  可得

$$\begin{aligned} f(\lambda) &= \sum_{n=1}^N \lambda_n z_n^T z_n - \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m z_n^T z_m \\ &= \sum_{n=1}^N \lambda_n K(x_n, x_n) - \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m K(x_n, x_m) \end{aligned}$$

## Problem 10

由Problem 6的推导过程我们可知，

$$\lambda_n (||x_n - c||^2 - R^2) = 0$$

$$n = 1, \dots, N$$

这里讨论的是特征转换之后的问题，所以上述问题可以修改为

$$\lambda_n (||z_n - c||^2 - R^2) = 0$$

$$n = 1, \dots, N$$

所以如果存在  $\lambda_i \neq 0$ ，那么

$$||z_i - c||^2 - R^2 = 0$$

结合  $c = \sum_{n=1}^N \lambda_n z_n$ ，可得

$$\begin{aligned}
R^2 &= \|z_i - c\|^2 \\
&= (z_i - \sum_{n=1}^N \lambda_n z_n)^T (z_i - \sum_{n=1}^N \lambda_n z_n) \\
&= z_i^T z_i - 2 \sum_{n=1}^N \lambda_n z_n^T z_i + \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m z_n^T z_m \\
&= K(x_i, x_i) - 2 \sum_{n=1}^N \lambda_n K(x_n, x_i) + \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m K(x_n, x_m)
\end{aligned}$$

## Problem 11

首先看下现在的问题，假设假设  $x_n \in \mathbb{R}^k$

$$\begin{aligned}
&\min_{w, b, \xi} \frac{1}{2} w^T w + C \sum_{n=1}^N \xi_n^2 \\
&\text{subject to } y_n(w^T x_n + b) \geq 1 - \xi_n
\end{aligned}$$

转换成hard-margin的关键问题在于把  $\frac{1}{2} w^T w + C \sum_{n=1}^N \xi_n^2$  写成  $\frac{1}{2} \tilde{w}^T \tilde{w}$

$$\frac{1}{2} w^T w + C \sum_{n=1}^N \xi_n^2 = \frac{1}{2} (w^T w + 2C \sum_{n=1}^N \xi_n^2)$$

从这点可以想到

$$\tilde{w} = \begin{bmatrix} w \\ \sqrt{2C}\xi_1 \\ \vdots \\ \sqrt{2C}\xi_N \end{bmatrix}$$

从而

$$\tilde{w}^T \tilde{w} = w^T w + 2C \sum_{n=1}^N \xi_n^2$$

这样变换之后也要对条件进行变换，将条件化为  $y_n(w^T \tilde{x}_n + b) \geq 1$  的形式

$$\begin{aligned}
y_n(w^T x_n + b) &\geq 1 - \xi_n \Leftrightarrow \\
y_n(w^T x_n + b + y_n \xi_n) &\geq 1 \Leftrightarrow \\
y_n(w^T x_n + \sqrt{2C}\xi_n (\frac{1}{\sqrt{2C}} y_n) + b) &\geq 1
\end{aligned}$$

结合  $\tilde{w}$  的式子，我们可以定义  $\tilde{x}_n$ ，注意  $x_n \in \mathbb{R}^k$

$$\tilde{x}_n = \begin{bmatrix} x_n \\ 0 \\ \dots \\ \frac{1}{\sqrt{2C}} y_n \\ \dots \\ 0 \end{bmatrix} \in \mathbb{R}^{k+N}$$

其中 $\tilde{x}_n$ 的第 $k+1$ 到 $k+N$ 的分量中，除了第 $k+n$ 个为 $\frac{1}{\sqrt{2C}} y_n$ ，其余均为0，这样就把问题转化为

$$\begin{aligned} \min_{w,b,\xi} \quad & \frac{1}{2} \tilde{w}^T \tilde{w} \\ \text{subject to} \quad & y_n (\tilde{w}^T x_n + b) \geq 1 \end{aligned}$$

如果已经计算出了 $\tilde{w}$ ，那么由于

$$\tilde{w} = \begin{bmatrix} w \\ \sqrt{2C}\xi_1 \\ \dots \\ \sqrt{2C}\xi_N \end{bmatrix}$$

所以取 $\tilde{w}$ 的前 $k$ 个分量即可得到 $w$ 。

## Problem 12

只要看这些映射对应的Gram矩阵是否半正定即可，设 $K, K_1, K_2$ 对应的Gram矩阵为 $M, M_1, M_2$

(a)  $K(x, x') = K_1(x, x') + K_2(x, x')$  可得  $M = M_1 + M_2$

$$y^T M y = y^T (M_1 + M_2) y = y^T M_1 y + y^T M_2 y \geq 0$$

所以 $K(x, x') = K_1(x, x') + K_2(x, x')$ 为kernel

(b)  $K(x, x') = K_1(x, x') - K_2(x, x')$  可得  $M = M_1 - M_2$

这个一看就不是kernel，反例也很好构造

$$M_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, M_2 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}, M = M_1 - M_2 = \begin{bmatrix} -1 & 0 \\ 0 & -1 \end{bmatrix}$$

显然 $M$ 不是半正定的，所以 $K(x, x') = K_1(x, x') - K_2(x, x')$ 不是kernel

(c) 首先计算下式子的形式。

$$\begin{aligned}
K(x, x') &= K_1(x, x')K_2(x, x') = \phi_1(x)^T \phi_1(x') \phi_2(x)^T \phi_2(x') \\
&= \sum_{i=1}^n \phi_1^i(x) \phi_1^i(x') \sum_{j=1}^n \phi_2^j(x) \phi_2^j(x') \\
&= \sum_{i=1}^n \sum_{j=1}^n \phi_1^i(x) \phi_1^i(x') \phi_2^j(x) \phi_2^j(x') \\
&= \sum_{i=1}^n \sum_{j=1}^n (\phi_1^i(x) \phi_2^j(x)) (\phi_1^i(x') \phi_2^j(x'))
\end{aligned}$$

根据这个形式，可以做以下定义

$$\begin{aligned}
\Phi^i(x) &= \phi_1^i(x) (\phi_1^1(x), \dots, \phi_2^n(x)) \\
\Phi(x) &= (\Phi^1(x), \dots, \Phi^n(x))^T
\end{aligned}$$

我们来计算下这个式子

$$\begin{aligned}
(\Phi^i(x))^T (\Phi^i(x')) &= \sum_{j=1}^n (\phi_1^i(x) \phi_2^j(x)) (\phi_1^i(x') \phi_2^j(x')) \\
(\Phi(x))^T \Phi(x') &= \sum_{i=1}^n (\Phi^i(x))^T (\Phi^i(x')) = \sum_{i=1}^n \sum_{j=1}^n (\phi_1^i(x) \phi_2^j(x)) (\phi_1^i(x') \phi_2^j(x')) = K(x, x')
\end{aligned}$$

根据核函数的定义可知， $K(x, x') = K_1(x, x')K_2(x, x')$ 为kernel

$$(d) K(x, x') = K_1(x, x')/K_2(x, x')$$

这个也不是kernel，反例如下

$$M_1 = \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix}, M_2 = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}, M = M_1/M_2 = \begin{bmatrix} \frac{1}{2} & 2 \\ 2 & 3 \end{bmatrix}$$

$M$ 行列式小于0，所以必然不是半正定的，所以 $K(x, x') = K_1(x, x')/K_2(x, x')$ 不是kernel

所以这题答案为(a)(c)。

### Problem 13

设 $K, K_1$ 对应的Gram矩阵为 $M, M_1$

(a)

$$M_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, M = \begin{bmatrix} (1-1)^2 & (1-0)^2 \\ (1-0)^2 & (1-1)^2 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

$M$ 的行列式小于0，所以 $K(x, x') = (1 - K_1(x, x'))^2$ 不是kernel

(b)

$$M = 1126M_1$$

因为 $M_1$ 半正定, 所以 $M$ 半正定, 从而 $K(x, x') = 1126K_1(x, x')$ 是kernel

(c)

$$M_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, M = \begin{bmatrix} e^{-1} & 1 \\ 1 & e^{-1} \end{bmatrix}$$

$M$ 的行列式小于0, 所以 $K(x, x') = \exp(-K_1(x, x'))$ 不是kernel

(d)利用 $f(x) = \frac{1}{1-x}$ 在 $(0, 1)$ 区间的泰勒展开可得

$$\begin{aligned} K(x, x') &= (1 - K_1(x, x'))^{-1} \\ &= \sum_{i=0}^{+\infty} (K_1(x, x'))^i \end{aligned}$$

由上题的(b)我们知道 $K_1(x, x')^i$ 为kernel, 再有上题的(a)我们知道kernel的和也为kernel, 所以

$$K(x, x') = \sum_{i=0}^{+\infty} (K_1(x, x'))^i$$

也为kernel

## Problem 14

首先回顾下对偶问题对应的QP问题

$$\begin{aligned} &\underset{\alpha \in \mathbb{R}^N}{\text{minimize}} : \frac{1}{2} \alpha^T Q_D \alpha - 1_N^T \alpha \\ &\text{subject to: } A_D \alpha \geq u \end{aligned}$$

$$Q_D = \begin{bmatrix} y_1 y_1 K_{11} & \dots & y_1 y_N K_{1N} \\ y_2 y_1 K_{12} & \dots & y_2 y_N K_{2N} \\ \dots & \dots & \dots \\ y_N y_1 K_{N1} & \dots & y_N y_N K_{NN} \end{bmatrix}, A_D = \begin{bmatrix} y^T \\ -y^T \\ I_{N \times N} \\ -I_{N \times N} \end{bmatrix}, u = \begin{bmatrix} 0 \\ 0 \\ 0_{N \times N} \\ C \times I_{N \times N} \end{bmatrix}$$

我们来看如果用新的kernel,  $\tilde{K}(x, x') = pK(x, x') + q$ , 并且 $\tilde{C} = \frac{C}{p}$ 会产生什么情况:

$$\begin{aligned}
\tilde{Q}_D &= \begin{bmatrix} y_1 y_1 \tilde{K}_{11} & \dots & y_1 y_N \tilde{K}_{1N} \\ y_2 y_1 \tilde{K}_{12} & \dots & y_2 y_N \tilde{K}_{2N} \\ \dots & \dots & \dots \\ y_N y_1 \tilde{K}_{N1} & \dots & y_N y_N \tilde{K}_{NN} \end{bmatrix} \\
&= \begin{bmatrix} y_1 y_1 (pK_{11} + q) & \dots & y_1 y_N (pK_{1N} + q) \\ y_2 y_1 (pK_{12} + q) & \dots & y_2 y_N (pK_{2N} + q) \\ \dots & \dots & \dots \\ y_N y_1 (pK_{N1} + q) & \dots & y_N y_N (pK_{NN} + q) \end{bmatrix} \\
&= pQ_D + q(y_1, \dots, y_N)^T (y_1, \dots, y_N) \\
&\quad \tilde{A}_D = A_D \\
\tilde{u} &= \begin{bmatrix} 0 \\ 0 \\ 0_{N \times N} \\ \tilde{C} \times I_{N \times N} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0_{N \times N} \\ \frac{C}{p} \times I_{N \times N} \end{bmatrix} = \frac{1}{p} u
\end{aligned}$$

接着我们来计算 $\alpha^T \tilde{Q}_D \alpha$ , 注意

$$(y_1, \dots, y_N) \cdot \alpha = 0$$

所以

$$\alpha^T \tilde{Q}_D \alpha = \alpha^T pQ_D \alpha + \alpha^T q(y_1, \dots, y_N)^T (y_1, \dots, y_N) \alpha = p\alpha^T Q_D \alpha$$

所以我们的目标函数为

$$\frac{1}{2} \alpha^T \tilde{Q}_D \alpha - 1_N^T \alpha = \frac{1}{2} p \alpha^T Q_D \alpha - 1_N^T \alpha = \frac{1}{p} \left[ \frac{1}{2} (p\alpha)^T Q_D (p\alpha) - 1_N^T (p\alpha) \right]$$

由于 $p$ 为常数, 所以目标函数可以简化为

$$\frac{1}{2} (p\alpha)^T Q_D (p\alpha) - 1_N^T (p\alpha)$$

再看下限制条件

$$\tilde{A}_D \alpha \geq \tilde{u} \Leftrightarrow A_D \alpha \geq \frac{1}{p} u \Leftrightarrow A_D (p\alpha) \geq u$$

我们令 $\bar{\alpha} = p\alpha$ , 那么问题可以转换为

$$\begin{aligned}
& \underset{\alpha \in R^N}{\text{minimize}} : \frac{1}{2} \bar{\alpha}^T Q_D \bar{\alpha} - 1_N^T \bar{\alpha} \\
& \text{subject to: } A_D \bar{\alpha} \geq u \\
Q_D = & \begin{bmatrix} y_1 y_1 K_{11} & \dots & y_1 y_N K_{1N} \\ y_2 y_1 K_{12} & \dots & y_2 y_N K_{2N} \\ \dots & \dots & \dots \\ y_N y_1 K_{N1} & \dots & y_N y_N K_{NN} \end{bmatrix}, A_D = \begin{bmatrix} y^T \\ -y^T \\ I_{N \times N} \\ -I_{N \times N} \end{bmatrix}, u = \begin{bmatrix} 0 \\ 0 \\ 0_{N \times N} \\ C \times I_{N \times N} \end{bmatrix}
\end{aligned}$$

可以看出，这个问题和原问题是一致的，记原问题的最优解为 $\alpha^*$ ，那么该问题的最优解 $\tilde{\alpha}^*$ 满足以下条件

$$\alpha^* = p \tilde{\alpha}^*$$

我们根据这个条件开始讨论问题。

回顾下soft-margin得到的计算公式

$$\begin{aligned}
w^* &= \sum_{n=1}^N \alpha_n^* y_n z_n \\
\beta_n^* &= C - \alpha_n^* (n = 1, \dots, N) \\
b^* &= y_m - w^{*T} z_m = y_m - \left( \sum_{n=1}^N \alpha_n^* y_n z_n \right)^T z_m = y_m - \sum_{n=1}^N \alpha_n^* y_n K(x_n, x_m) \\
&\text{其中 } z_m \text{ 对应的 } \alpha_m^* \neq 0 \\
g(x) &= \text{sign}(w^{*T} z + b) = \text{sign}\left(\left(\sum_{n=1}^N \alpha_n^* y_n z_n\right)^T z + b\right) = \text{sign}\left(\sum_{n=1}^N \alpha_n^* y_n K(x_n, x) + b^*\right)
\end{aligned}$$

如果我们将kernel换成

$$\tilde{K}(x, x') = pK(x, x') + q$$

利用之前的条件 $\alpha^* = p \tilde{\alpha}^*$ 以及 $\tilde{C} = \frac{C}{p}$ ,  $\sum_{n=1}^N \alpha_n^* y_n = 0$ ，可以对变换kernel之后的问题求解

$$\begin{aligned}
\tilde{w}^* &= \sum_{n=1}^N \tilde{\alpha}_n^* y_n z_n = \frac{1}{p} \left( \sum_{n=1}^N \alpha_n^* y_n z_n \right) = \frac{w^*}{p} \\
\tilde{\beta}_n^* &= \tilde{C} - \tilde{\alpha}_n^* = \frac{C}{p} - \frac{\alpha_n^*}{p} = \frac{1}{p} (C - \alpha_n^*) = \frac{\beta_n^*}{p} (n = 1, \dots, N)
\end{aligned}$$



$$\begin{aligned}
\tilde{b}^* &= y_m - \sum_{n=1}^N \tilde{\alpha}_n^* y_n \tilde{K}(x_n, x_m) \\
&= y_m - \sum_{n=1}^N \frac{\alpha_n^*}{p} y_n (pK(x_n, x_m) + q) \\
&= y_m - \sum_{n=1}^N \alpha_n^* y_n K(x_n, x_m) - \frac{q}{p} \sum_{n=1}^N \alpha_n^* y_n \\
&= y_m - \sum_{n=1}^N \alpha_n^* y_n K(x_n, x_m) \\
&= b^*
\end{aligned}$$

$$\begin{aligned}
\tilde{g}(x) &= \text{sign}\left(\sum_{n=1}^N \tilde{\alpha}_n^* y_n \tilde{K}(x_n, x) + \tilde{b}^*\right) \\
&= \text{sign}\left[\sum_{n=1}^N \frac{\alpha_n^*}{p} y_n (pK(x_n, x) + q) + b^*\right] \\
&= \text{sign}\left[\sum_{n=1}^N \alpha_n^* y_n K(x_n, x) + \frac{q}{p} \sum_{n=1}^N \alpha_n^* y_n + b^*\right] \\
&= \text{sign}\left(\sum_{n=1}^N \alpha_n^* y_n K(x_n, x) + b^*\right) \\
&= g(x)
\end{aligned}$$

这说明这样变换之后我们的分类器没有变。

## Problem 15

首先读取数据并作图

```

# -*- coding: utf-8 -*-
"""
Created on Wed Mar 27 13:42:18 2019

@author: qinzhen
"""

####Problem 15
import matplotlib.pyplot as plt
import numpy as np
from sklearn import svm

def transformdata(file):
    data = np.genfromtxt(file)
    y, x = data[:, 0], data[:, 1:]
    return x, y


```

```

train = "featurestrain.txt"
X_train, y_train = transformdata(train)
test = "featurestest.txt"
X_test, y_test = transformdata(test)

#作图
plt.scatter(X_train[y_train == 0][:, 0], X_train[y_train == 0][:, 1], s=1, label='0')
plt.scatter(X_train[y_train != 0][:, 0], X_train[y_train != 0][:, 1], s=1, label='not 0')
plt.title('0 VS not 0')
plt.legend()
plt.show()

```



接着训练模型并作图：

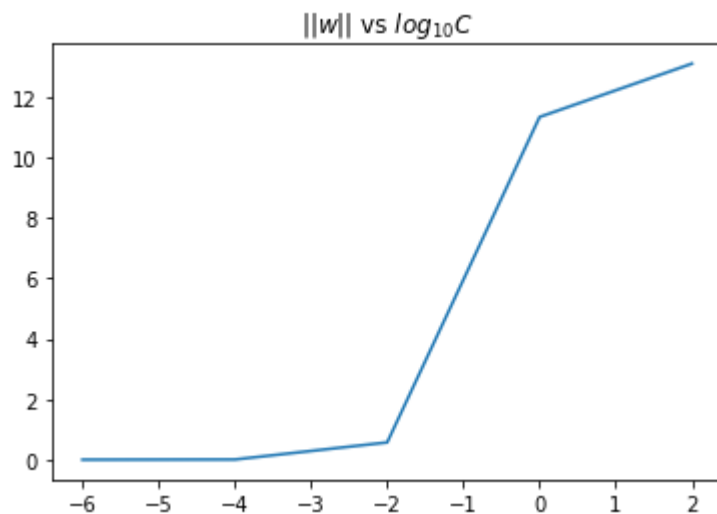
```

#训练模型并作图
y_train_1 = (y_train==0).astype("int")
C = [-6, -4, -2, 0, 2]
w = []

for i in C:
    c = 10 ** i
    clf = svm.SVC(kernel="linear", C=c)
    clf.fit(X_train, y_train_1)
    w = clf.coef_
    w.append(np.linalg.norm(w))

plt.plot(C, w)
plt.title("$||w||$ vs $\log_{10}C$")
plt.show()

```




## Problem 16

注意这题是8和not 8，首先作图

####Problem 16

```
plt.scatter(X_train[y_train == 8][:, 0], X_train[y_train == 8][:, 1], s=1, label='8')
plt.scatter(X_train[y_train != 8][:, 0], X_train[y_train != 8][:, 1], s=1, label='not 8')
plt.title('8 VS not 8')
plt.legend()
plt.show()
```



注意17题要计算 $\sum_{n=1}^N \alpha_n$ ，所以我们这题把系数也算出来，由于sklearn只能计算对偶系数 $y_n \alpha_n$ ，所以这里要把标签转换为+1, -1，方便计算。

#训练

```
y_train_8 = 2 * (y_train==8).astype("int") - 1
C = [-6, -4, -2, 0, 2]
Ein = []
alpha = []
for i in C:
```

```

c = 10 ** i
clf = svm.SVC(kernel='poly', degree=2, coef0=1, gamma=1, C=c)
clf.fit(X_train, y_train_8)
e = np.mean(clf.predict(X_train) != y_train_8)
#支持向量的索引
support = clf.support_
#计算系数
coef = np.sum(clf.dual_coef_[0] * y_train_8[support])
alpha.append(coef)
Ein.append(e)

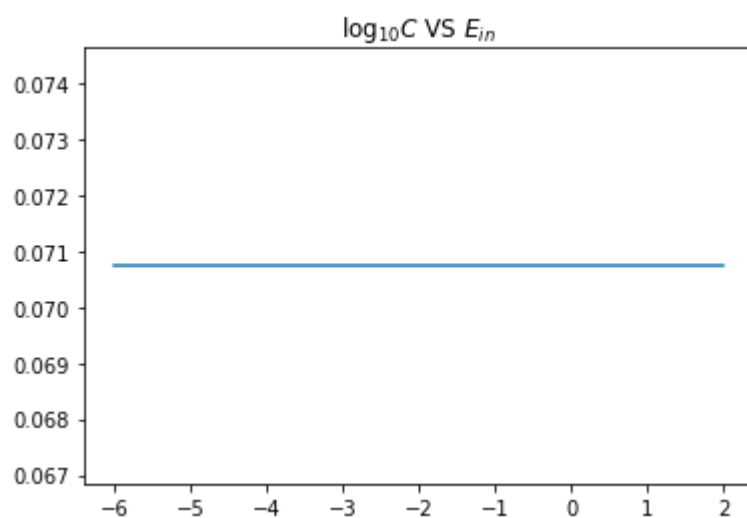
```

#作图

```

plt.plot(C, Ein)
plt.show()

```



比较神奇的是这题的 $E_{in}$ 都一样。


## Problem 17

利用上题的数据作图即可。

```

####Problem 17
plt.plot(C, alpha)
plt.title("$\log_{10}C$ vs sum_alpha")
plt.show()

```



可以看到尽管上题的  $E_{\text{in}}$  一致，但是这里  $\sum_{n=1}^N \alpha_n$  会增加。

## Problem 18

这题需要计算权重  $w$ ，因为涉及到高斯核，无法直接计算。

现在假设有  $n$  个样本，那么：

$$w = \sum_{i=1}^n \alpha_i y_i z_i, z_i = \Phi(x_i)$$

$$\|w\|^2 = \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \alpha_j y_j z_i^T z_j = \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \alpha_j y_j z_i^T z_j K(x_i, x_j)$$

其中

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

记

$$\bar{y} = \begin{bmatrix} \alpha_1 y_1 \\ \vdots \\ \alpha_n y_n \end{bmatrix} \in \mathbb{R}^n, D \in \mathbb{R}^{n \times n}, D_{ij} = \|x_i - x_j\|^2$$

那么

$$K = \exp(-\gamma D)$$

并且

$$\|w\|^2 = \bar{y}^T K \bar{y}$$

注意只有支持向量部分的系数非零，所以上述计算步骤只要对支持向量进行即可（clf.support\_ 为支持向量的索引），所以只要计算出  $D$  即可，这里介绍向量化的计算方法，考虑更一般的问题：

假设

$$X = \begin{bmatrix} -(x^{(1)})^T & - \\ -(x^{(2)})^T & - \\ \vdots & \\ -(x^{(m)})^T & - \end{bmatrix} \in \mathbb{R}^{m \times d}, Y = \begin{bmatrix} -(y^{(1)})^T & - \\ -(y^{(2)})^T & - \\ \vdots & \\ -(y^{(n)})^T & - \end{bmatrix} \in \mathbb{R}^{n \times d}$$

其中  $x^{(i)}, y^{(j)} \in \mathbb{R}^d$ , 现在的问题是如何高效计算矩阵  $D \in \mathbb{R}^{m \times n}$ , 其中

$$D_{i,j} = \|x^{(i)} - y^{(j)}\|^2$$

首先对  $D_{i,j}$  进行处理

$$\begin{aligned} D_{i,j} &= \|x^{(i)} - y^{(j)}\|^2 \\ &= (x^{(i)} - y^{(j)})^T (x^{(i)} - y^{(j)}) \\ &= (x^{(i)})^T x^{(i)} - 2(x^{(i)})^T y^{(j)} + (y^{(j)})^T y^{(j)} \end{aligned}$$

那么

$$\begin{aligned} D &= \begin{bmatrix} D_{1,1} & \dots & D_{1,n} \\ \dots & \dots & \dots \\ D_{m,1} & \dots & D_{m,n} \end{bmatrix} \\ &= \begin{bmatrix} (x^{(1)})^T x^{(1)} - 2(x^{(1)})^T y^{(1)} + (y^{(1)})^T y^{(1)} & \dots & (x^{(1)})^T x^{(1)} - 2(x^{(1)})^T y^{(n)} + (y^{(n)})^T y^{(n)} \\ \dots & \dots & \dots \\ (x^{(m)})^T x^{(m)} - 2(x^{(m)})^T y^{(1)} + (y^{(1)})^T y^{(1)} & \dots & (x^{(m)})^T x^{(m)} - 2(x^{(m)})^T y^{(n)} + (y^{(n)})^T y^{(n)} \end{bmatrix} \\ &= \begin{bmatrix} (x^{(1)})^T x^{(1)} & \dots & (x^{(1)})^T x^{(1)} \\ \dots & \dots & \dots \\ (x^{(m)})^T x^{(m)} & \dots & (x^{(m)})^T x^{(m)} \end{bmatrix} + \begin{bmatrix} (y^{(1)})^T y^{(1)} & \dots & (y^{(n)})^T y^{(n)} \\ \dots & \dots & \dots \\ (y^{(1)})^T y^{(1)} & \dots & (y^{(n)})^T y^{(n)} \end{bmatrix} - 2 \begin{bmatrix} (x^{(1)})^T y^{(1)} & \dots & (x^{(1)})^T y^{(n)} \\ \dots & \dots & \dots \\ (x^{(m)})^T y^{(1)} & \dots & (x^{(m)})^T y^{(n)} \end{bmatrix} \\ &= \begin{bmatrix} (x^{(1)})^T x^{(1)} \\ \dots \\ (x^{(m)})^T x^{(m)} \end{bmatrix} \underbrace{\begin{bmatrix} 1 & \dots & 1 \end{bmatrix}}_{1 \times n \text{ 矩阵}} + \underbrace{\begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}}_{m \times 1 \text{ 矩阵}} \begin{bmatrix} (y^{(1)})^T y^{(1)} & \dots & (y^{(n)})^T y^{(n)} \end{bmatrix} - 2XY^T \end{aligned}$$

利用numpy的广播机制上式可以简写如下:

```
#计算距离矩阵
d1 = np.sum(X ** 2, axis=1).reshape(-1, 1)
d2 = np.sum(Y ** 2, axis=1).reshape(1, -1)
dist = d1 + d2 - 2 * X.dot(Y.T)
```

利用上述方法计算  $\|w\|^2$  即可, 最后注意距离为  $\frac{1}{\|w\|}$ :

```
####Problem 18
C = [-3, -2, -1, 0, 1]
Distance = []
```


```

#将标签修改为-1, 1
y = 2 * y_train_1 - 1

for i in C:
    c = 10**i
    clf = svm.SVC(kernel='rbf', gamma=1, C=c)
    clf.fit(X_train, y)
    x = X_train[clf.support_]
    #距离矩阵
    d1 = np.sum(x ** 2, axis=1).reshape(-1, 1)
    d2 = np.sum(x ** 2, axis=1).reshape(1, -1)
    dist = d1 + d2 - 2 * x.dot(x.T)
    #kernel矩阵
    K = np.exp(- c * dist)
    #计算any
    y1 = clf.dual_coef_[0] * y[clf.support_]
    w2 = y1.dot(K).dot(y1.T)
    #计算距离
    distance = 1 / np.sqrt(w2)
    Distance.append(distance)

plt.plot(C, Distance)
plt.title("$\log_{10}C$ VS distance")
plt.show()

```



随着 $C$ 增加，距离在减少。

## Problem 19

```

####Problem 19
y_test_1 = (y_test == 0)

Gamma = range(5)
Eout = []

for i in Gamma:

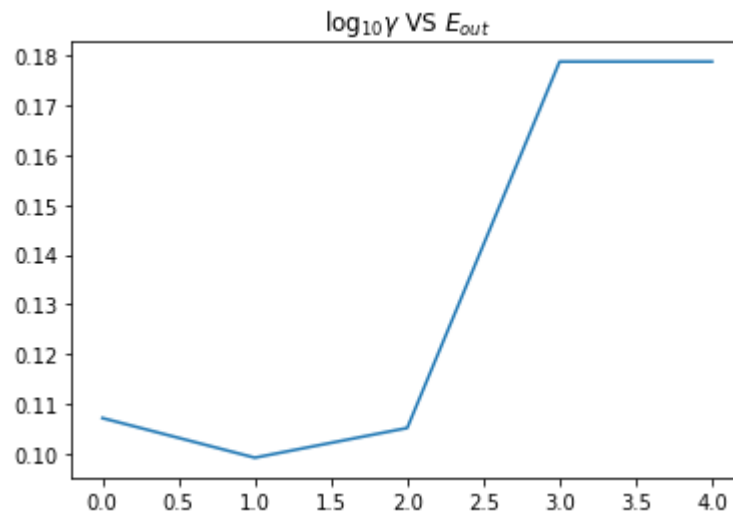
```

```

gamma = 10**i
clf = svm.SVC(kernel='rbf', gamma=gamma, C=0.1)
clf.fit(X_train, y_train_1)
e = np.mean(clf.predict(X_test) != y_test_1)
Eout.append(e)

plt.plot(Gamma, Eout)
plt.title("$\log_{10}\gamma$ VS $E_{out}$")
plt.show()

```



可以看到,  $\log_{10} \gamma = 1$  时,  $E_{out}$  最小, 说明  $C$  不能太大, 也不能太小。

## Problem 20

这题要构造交叉验证集, 多次实验, 做直方图, 先做一些预处理。

```

####Problem 20
from sklearn.model_selection import train_test_split

#对数据合并, 方便调用train_test_split函数
Data = np.c_[X_train, y_train]
N = 100
#记录最小Eval对应的gamma的索引的次数
Cnt = np.zeros(5)
Gamma = range(5)

for _ in range(N):
    #划分数据
    train_set, val_set = train_test_split(Data, test_size=0.2)
    #取特征
    X_train = train_set[:, :2]
    #取标签
    y_train = train_set[:, 2]
    X_val = val_set[:, :2]
    y_val = val_set[:, 2]
    Eval = []

```




```

for i in Gamma:
    gamma = 10 ** i
    clf = svm.SVC(kernel='rbf', gamma=gamma, C=0.1)
    clf.fit(X_train, y_train)
    e = np.mean(clf.predict(X_val) != y_val)
    Eval.append(e)
#找到最小Eval对应的索引
index = np.argmin(Eval)
#对应索引次数加1
Cnt[index] += 1

plt.bar(Gamma, Cnt)
plt.show()

```



可以看到大部分最优解对应的 $\log_{10}\gamma$ 都为1，和上一题说明同一个道理，说明 $\gamma$ 不能太大，也不能太小。

附加题

## Problem 21

这题的问题是求hard-margin SVM对偶问题的对偶问题，我们来看一下。

首先回顾下hard-margin SVM对偶问题。

$$\begin{aligned}
 &\underset{\alpha \in \mathbb{R}^N}{\text{minimize}} : \frac{1}{2} \sum_{m=1}^N \sum_{n=1}^N y_n y_m \alpha_n \alpha_m x_n^T x_m - \sum_{n=1}^N \alpha_n \\
 &\text{subject to: } \sum_{n=1}^N y_n \alpha_n = 0, \alpha_n \geq 0 (n = 1, \dots, N)
 \end{aligned}$$

根据拉格朗日乘子法，我们将上述问题转化为

$$\min_{\alpha \in \mathbb{R}^N} \max_{\lambda_i \geq 0} : \frac{1}{2} \sum_{m=1}^N \sum_{n=1}^N y_n y_m \alpha_n \alpha_m x_n^T x_m - \sum_{n=1}^N \alpha_n + \lambda_0 \left( \sum_{n=1}^N y_n \alpha_n \right) - \sum_{n=1}^N \lambda_n \alpha_n$$

注意这里如下事实成立：

$$\min \max = \max \min$$

所以上述问题可以转化为

$$\max_{\lambda_i \geq 0} \min_{\alpha \in \mathbb{R}^N} : \frac{1}{2} \sum_{m=1}^N \sum_{n=1}^N y_n y_m \alpha_n \alpha_m x_n^T x_m - \sum_{n=1}^N \alpha_n + \lambda_0 \left( \sum_{n=1}^N y_n \alpha_n \right) - \sum_{n=1}^N \lambda_n \alpha_n$$

这个最小值问题转化为为一个无条件极值，现在做以下记号

$$f(\lambda, \alpha) = \frac{1}{2} \sum_{m=1}^N \sum_{n=1}^N y_n y_m \alpha_n \alpha_m x_n^T x_m - \sum_{n=1}^N \alpha_n + \lambda_0 \left( \sum_{n=1}^N y_n \alpha_n \right) - \sum_{n=1}^N \lambda_n \alpha_n$$

关于 $\alpha_i$ 求偏导可得

$$\begin{aligned} \frac{\partial f}{\partial \alpha_i} &= \frac{1}{2} \sum_{n=1}^N y_n y_i \alpha_n x_n^T x_i + \frac{1}{2} \sum_{m=1}^N y_i y_m \alpha_m x_i^T x_m - 1 + \lambda_0 y_i - \lambda_i \\ &= \sum_{n=1}^N y_n y_i \alpha_n x_i^T x_n - 1 + \lambda_0 y_i - \lambda_i \end{aligned}$$

令偏导为0可得

$$\sum_{n=1}^N y_n y_i \alpha_n x_i^T x_n = 1 - \lambda_0 y_i + \lambda_i$$

对这个式子作以下变形可得

$$\begin{bmatrix} y_i y_1 x_i^T x_1 & \dots & y_i y_N x_i^T x_N \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \dots \\ \alpha_N \end{bmatrix} = 1 - \lambda_0 y_i + \lambda_i \quad (1)$$

这个形式是见过的，我们回顾下Learning from data第八章的28页，我们知道hard-margin SVM对偶问题也可以写成如下的形式

$$\begin{aligned} &\underset{\alpha \in \mathbb{R}^N}{\text{minimize}} : \frac{1}{2} \alpha^T Q_D \alpha - 1_N^T \alpha \\ &\text{subject to: } A_D \alpha \geq 0_{N+2} \\ Q_D &= \begin{bmatrix} y_1 y_1 x_1^T x_1 & \dots & y_1 y_N x_1^T x_N \\ y_2 y_1 x_2^T x_1 & \dots & y_2 y_N x_2^T x_N \\ \dots & \dots & \dots \\ y_N y_1 x_N^T x_1 & \dots & y_N y_N x_N^T x_N \end{bmatrix} \text{ and } A_D = \begin{bmatrix} y^T \\ -y^T \\ I_{N \times N} \end{bmatrix} \end{aligned}$$

(1)的等式左边的第一个向量对应着 $Q_D$ 的每一行，所以如果我们对(1)式中 $i$ 从1取到 $N$ ，可以把(1)的条件转化为

$$Q_D \alpha = 1_N - \lambda_0 y + \lambda$$

$$\alpha = \begin{bmatrix} \alpha_1 \\ \dots \\ \alpha_N \end{bmatrix}, y = \begin{bmatrix} y_1 \\ \dots \\ y_N \end{bmatrix}, \lambda = \begin{bmatrix} \lambda_1 \\ \dots \\ \lambda_N \end{bmatrix}$$

在这个记号下，对原问题进行处理

$$\sum_{m=1}^N \sum_{n=1}^N y_n y_m \alpha_n \alpha_m x_n^T x_m = \alpha^T Q_D \alpha$$

$$\sum_{n=1}^N \alpha_n = 1_N^T \alpha$$

$$\lambda_0 \left( \sum_{n=1}^N y_n \alpha_n \right) = \lambda_0 \alpha^T y$$

$$\sum_{n=1}^N \lambda_n \alpha_n = \alpha^T \lambda$$

所以

$$f(\lambda, \alpha) = \frac{1}{2} \alpha^T Q_D \alpha - 1_N^T \alpha + \lambda_0 \alpha^T y - \alpha^T \lambda$$

将  $Q_D \alpha = 1_N - \lambda_0 y + \lambda$  带入可得

$$\begin{aligned} f(\lambda, \alpha) &= \frac{1}{2} \alpha^T Q_D \alpha - 1_N^T \alpha + \lambda_0 \alpha^T y - \alpha^T \lambda \\ &= \frac{1}{2} \alpha^T (1_N - \lambda_0 y + \lambda) - 1_N^T \alpha + \lambda_0 \alpha^T y - \alpha^T \lambda \\ &= -\frac{1}{2} \alpha^T 1_N + \frac{1}{2} \lambda_0 \alpha^T y - \frac{1}{2} \alpha^T \lambda \\ &= -\frac{1}{2} \alpha^T (1_N - \lambda_0 y + \lambda) \end{aligned}$$

如果  $Q_D$  可逆，那么

$$\alpha = Q_D^{-1} (1_N - \lambda_0 y + \lambda)$$

代入可得

$$\begin{aligned} -\frac{1}{2} \alpha^T (1_N - \lambda_0 y + \lambda) &= -\frac{1}{2} [Q_D^{-1} (1_N - \lambda_0 y + \lambda)]^T (1_N - \lambda_0 y + \lambda) \\ &= -\frac{1}{2} (1_N - \lambda_0 y + \lambda)^T Q_D^{-1} (1_N - \lambda_0 y + \lambda) \end{aligned}$$

所以问题转化为

$$\begin{aligned} \underset{\lambda_i \geq 0}{\text{maximize}} : & -\frac{1}{2}(1_N - \lambda_0 y + \lambda)^T Q_D^{-1}(1_N - \lambda_0 y + \lambda) \\ \text{subject to: } & \lambda_i \geq 0 (n = 0, 1, \dots, N) \end{aligned}$$

把负号提出来，可以转化为标准的QP问题

$$\begin{aligned} \underset{\lambda_i \geq 0}{\text{minimize}} : & \frac{1}{2}(1_N - \lambda_0 y + \lambda)^T Q_D^{-1}(1_N - \lambda_0 y + \lambda) \\ \text{subject to: } & \lambda_i \geq 0 (n = 0, 1, \dots, N) \end{aligned}$$

可以看到，这和最开始的问题是非常类似的。